

## Ambient Assisted Living y modelos estocásticos

**Tommaso Papini**

STLab, Departamento de la Ingeniería de la Información, Universidad de Florencia, Italia,  
tommaso.papini@unifi.it

29 de Mayo 2017

Departamento de Informática, Universidad de Jaén, España

- ▶ Ambient Assisted Living
- ▶ Modelos y datasets
- ▶ Análisis de entornos inteligentes

## Overview

### Ambient Assisted Living

Objetivos

### Modelos y datasets

Modelos estocásticos

Datasets anotados

Process mining

### Análisis de entornos inteligentes

Diagnos

Predicción

Planificación de acciones

## Ambient Assisted Living

## Ambient Assisted Living

El **Ambient Assisted Living** es un sector de investigación que tiene como objetivo ayudar a las personas que viven en *entornos inteligentes* (es decir, dotados de sensores y actuadores) explotando a la tecnología de sensores y de procesamiento de datos.



## Objetivos

Un *entorno inteligente* es un sistema **parcialmente observable**:

- ▶ el estado efectivo del sistema resulta oculto;
- ▶ solo se pueden observar eventos (*observaciones*) emitidos por el sistema (por ej. la activación de un sensor).

Principales análisis de interés:

- ▶ **Diagnosis**: estimar cual es el estado efectivo actual del sistema a partir de las observaciones registradas.
- ▶ **Predicción**: estimar cual será el estado efectivo del sistema después de una determinada cantidad de tiempo o la densidad de probabilidad de que un evento se verifique.
- ▶ **Planificación de acciones**: elegir la acción óptima y entre cuanto tiempo debe desarrollarse para evitar situaciones críticas.

Análisis en línea:


- ▶ intenta analizar un entorno inteligente *mientras* está evolucionando.

## Modelos y datasets

## Modelos estocásticos

Los *modelos estocásticos* representan una aproximación de sistemas donde se modelan:


- ▶ la evolución del estado del sistema;
- ▶ parámetros estocásticos que definen como el sistema pasa de un estado al otro.



## Datasets anotados

Un *dataset anotado* es un dataset donde hay:

- ▶ los eventos registrados y cuando han pasado (marca temporal);
- ▶ anotaciones manuales de la evolución del estado efectivo del sistema (con intervalos temporales por cada estado).






## Datasets anotados

van Kasteren

Un ejemplo clásico de dataset anotado para AAL es el dataset de *van Kasteren*<sup>12</sup>



<sup>1</sup><https://sites.google.com/site/tim0306/datasets>

<sup>2</sup>Van Kasteren, T., Noulas, A., Englebienne, G. and Kröse, B., 2008, September. Accurate activity recognition in a home setting. In Proceedings of the 10th international conference on Ubiquitous computing (pp. 1-9). ACM.

## Process mining

### De datasets anotados a modelos estocásticos

Con el término **process mining** se indica un conjunto de técnicas para construir un modelo estocástico de un sistema parcialmente observable a partir de un dataset anotado de este mismo sistema.


El process mining está compuesto por dos técnicas principales:

- ▶ **Process elicitation:** construye un modelo discreto (es decir, sin informaciones sobre la permanencia en los estados del sistema) a partir de los eventos y actividades anotados en el dataset.
- ▶ **Process enhancement:** añade una visión temporal continua a un modelo discreto introduciendo parámetros estocásticos que describen como el sistema evoluciona a lo largo del tiempo utilizando medidas estadísticas sacadas por el dataset.

## Análisis de entornos inteligentes


# Análisis de entornos inteligentes

## Esquema general



- ▶ **Process mining:** de dataset anotado a modelo estocásticos.
- ▶ **Diagnosis:** de eventos efectivos a probabilidad del estado corriente (sobre un determinado modelo estocástico).
- ▶ **Predicción:** de probabilidad del estado corriente a probabilidad de que ocurra un evento crítico.
- ▶ **Planificación:** de probabilidad de que ocurra un evento crítico a tiempo de planificación de una reacción (con una determinada política de reacción).

## Diagnósis




La **diagnósis** calcula el estado efectivo mas probable del modelo en el instante corriente a partir de los eventos observados hasta el instante corriente.

## Diagnóstico

### Tiempo discreto

Los **Modelos Ocultos de Márkov** (Hidden Markov Model, HMM):

- ▶ modelan a un sistema parcialmente observable sin tener en cuenta el tiempo de permanencia en cada estado;
- ▶ asocian a cada estado efectivo del sistema una distribución discreta sobre los eventos observables;
- ▶ modelan a un sistema donde los estados efectivos evolucionan como una *Cadena de Márkov Tiempo Discreto* (Discrete Time Markov Chain, DTMC).



Diagnóstico con HMM se puede lograr con algoritmos clásicos como el *algoritmo de Viterbi* o el *algoritmo de Forward-Backward*.

## Diagnósis

### Tiempo discreto con permanencia

#### ▶ **HSMM<sup>3</sup>**

- ▶ Hidden Semi Markov Model;
- ▶ permanencia en los estados ocultos modelada con distribuciones de tiempo discreto;
- ▶ eventos generados en cada instante temporal.

#### ▶ **IS-HSMM/ILP-HSMM<sup>4</sup>**

- ▶ Interval State-Hidden Semi Markov Model;
- ▶ Interval Length Probability-Hidden Semi Markov Model;
- ▶ extensiones de los HSMMs;
- ▶ permite modelar a intervalos de silencio (es decir, sin eventos);

---

<sup>3</sup>Van Kasteren, T.L.M., Englebiene, G. and Kröse, B.J., 2010. Activity recognition using semi-markov models on real world smart home datasets. Journal of ambient intelligence and smart environments, 2(3), pp.311-325.

<sup>4</sup>Narimatsu, H. and Kasai, H., 2016. State Duration and Interval Modeling in Hidden Semi-Markov Model for Sequential Data Analysis. arXiv preprint arXiv:1608.06954.

# Diagnóstico

## Tiempo continuo

- ▶ **HnMM**<sup>5</sup>
  - ▶ Hidden nonMarkov Model;
  - ▶ tiempos de permanencia continuos;
  - ▶ cada *transición* (es decir, el pasaje de un estado al siguiente) produce un evento.
- ▶ **GHSMM**<sup>6</sup>
  - ▶ Generalized Hidden Semi Markov Process;
  - ▶ tiempo de permanencia continuo;
  - ▶ solo una observación por cada estado.

---

<sup>5</sup>Buchholz, R., Krull, C., Strigl, T. and Horton, G., 2010, March. Using hidden non-markovian models to reconstruct system behavior in partially-observable systems. In Proceedings of the 3rd International ICST Conference on Simulation Tools and Techniques (p. 86). ICST (Institute for Computer Sciences, Social-Informatics and Telecommunications Engineering).

<sup>6</sup>Salfner, F., 2006. Modeling event-driven time series with generalized hidden semi-Markov models.



## Diagnóstico

### H-MRGP-M

El **Modelo Oculto de Márkov Regenerativo** (Hidden-Markov Regenerative Process-Model) ha sido desarrollado por el STLab en la Universidad de Florencia.<sup>7</sup>

- ▶ Modela el tiempo continuo de permanencia en los estados y del inter-tiempo entre eventos.
- ▶ El estado del modelo evoluciona como un *Proceso Regenerativo de Márkov* (Markov Regenerative Process, MRP).

---

<sup>7</sup>Carnevali, L., Nugent, C., Patara, F. and Vicario, E., 2015, September. A continuous-time model-based approach to activity recognition for ambient assisted living. In International Conference on Quantitative Evaluation of Systems (pp. 38-53). Springer International Publishing.

## Diagnosis

### H-MRGP-M: medidas estadísticas

- ▶ Experimentado sobre el dataset de van Kasteren:
  - ▶ 7+1 actividades.
  - ▶ {Leaving house, Preparing a beverage, Preparing breakfast, Preparing dinner, Sleeping, Taking shower, Toileting}.
- ▶ A partir de las marcas temporales en el dataset anotado, se calculan medidas estadísticas sobre los tiempos continuos
  - ▶ de permanencia en cada actividad;
  - ▶ de inter-tiempo entre eventos en cada actividad.

	Tiempo de permanencia		Inter-tiempo entre eventos	
	$\mu$ (s)	CV	$\mu$ (s)	CV
<b>Leaving house</b>	40 261.455	1.042	9 354.190	2.810
<b>Preparing a beverage</b>	35.667	1.361	7.643	2.613
<b>Preparing breakfast</b>	108.684	0.713	9.928	1.844
<b>Preparing dinner</b>	1 801.889	0.640	77.966	2.589
<b>Sleeping</b>	26 116.571	0.442	1 871.836	3.090
<b>Taking shower</b>	485.910	0.298	102.788	1.969
<b>Toileting</b>	88.742	1.175	14.814	2.449

## Diagnóstico

### H-MRGP-M: modelo estocástico @runtime

- ▶ El modelo se crea con técnicas de *process mining*:
  - ▶ *process elicitation* para definir la topología del modelo;
  - ▶ *process enhancement* para añadir parámetros estocásticos a partir de las medidas estadísticas calculadas (técnica de Whitt<sup>8</sup> y software PhFit<sup>9</sup>).
- ▶ Modelo **@runtime**: modelo actualizado cada vez que se observa un nuevo evento.<sup>10</sup>
- ▶ El formalismo utilizado para representar al modelo es el de las **Redes de Petri Temporizadas estocásticas** (stochastic Timed Petri Net, sTPN).<sup>1112</sup>

---

<sup>8</sup>Whitt, W., 1982. Approximating a point process by a renewal process, I: Two basic methods. Operations Research, 30(1), pp.125-147.

<sup>9</sup>Horváth, A. and Telek, M., 2002, April. Phfit: A general phase-type fitting tool. In International Conference on Modelling Techniques and Tools for Computer Performance Evaluation (pp. 82-91). Springer Berlin Heidelberg.


<sup>10</sup>Blair, G., Bencomo, N. and France, R.B., 2009. Models@ run. time. Computer, 42(10).

<sup>11</sup>Horváth, A. and Vicario, E., 2009, September. Aggregated stochastic state classes in quantitative evaluation of non-markovian stochastic Petri nets. In Quantitative Evaluation of Systems, 2009. QEST'09. Sixth International Conference on the (pp. 155-164). IEEE.

<sup>12</sup>Vicario, E., 2001. Static analysis and dynamic steering of time-dependent systems. IEEE transactions on software engineering, 27(8), pp.728-748.

# Diagnósis

## H-MRGP-M: sTPN




## Diagnosis

### H-MRGP-M: análisis transitorio

Después de cada observación, se pueden calcular las probabilidades de estar en diferentes estados del sistema hasta la observación siguiente.

- Se explota a la técnica de análisis transitorio de Procesos Regenerativos de Markov basada en clases de estado estocásticas.<sup>13</sup>



El estado estimado por la diagnosis será el estado que lleva la probabilidad más alta.

<sup>13</sup>Horváth, A., Paolieri, M., Ridi, L. and Vicario, E., 2012. Transient analysis of non-Markovian models using stochastic state classes. Performance Evaluation, 69(7), pp.315-335.

## Diagnóstico

### H-MRGP-M: análisis transitorio




Después de haber observado el evento  $n$ , por cada actividad corriente *posible*

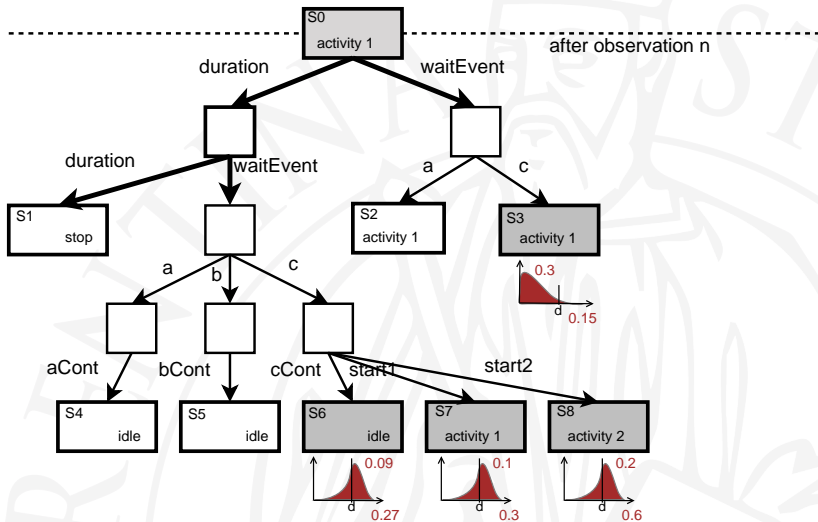
- ▶ se construye el árbol de las clases hasta que se encuentre la observación siguiente (evento  $n + 1$ );
- ▶ se seleccionan las hojas correspondientes al nuevo evento observado;
- ▶ se calcula la PDF de las hojas seleccionadas en el retraso  $d$  (inter-tiempo entre los eventos  $n$  y  $n + 1$ ) en cada árbol, sumandolas entre sí con peso la probabilidad de la raíz;
- ▶ se restituye el máximo como actividad más probable.

# Diagnosis

## H-MRGP-M: análisis transitorio




## H-MRGP-M: análisis transitorio





## Predicción



La **predicción**<sup>14</sup> calcula la densidad de probabilidad en el tiempo de que ocurra una determinada actividad crítica, a partir de la estimación sobre el estado corriente del modelo calculado por la diagnosis.


<sup>14</sup>Salfner, F., Lenk, M. and Malek, M., 2010. A survey of online failure prediction methods. ACM Computing Surveys (CSUR), 42(3), p.10.

## Predicción

### Modelo utilizado


Predicción de la densidad de probabilidad de una actividad crítica:

- ▶ Process enhancement sin elicitation:
  - ▶ probabilidades de transición calculadas por las medidas estadísticas sobre las marcas temporales.
- ▶ Estados *idle* especializados:
  - ▶ permite tener en cuenta la última actividad.
- ▶ Las actividades evolucionan como un *Proceso Semi Márkov* (Semi Markov Process, SMP).






# Predicción

## Calculo de la PDF




- ▶ Para cada estado posible, se calcula la densidad de probabilidad de alcanzar al estado crítico (análisis transitorio).
- ▶ Se suman entre sí las densidades de probabilidad a partir de cada estado posible, pesadas por la probabilidad de estar en cada estado.

 $PDF(t)_{A\_to\_F} * \pi_A$ 

 $PDF(t)_{B\_to\_F} * \pi_B$ 

 $PDF(t)_{to\_F}$ 


+

=

## Planificación de acciones




La **planificación de acciones** calcula el instante temporal óptimo para planificar una reacción oportuna a una determinada actividad crítica, a partir de la probabilidad de que dicha actividad ocurra (calculada por la predicción) y de una política de reacción (decidida por el usuario).

## Planificación de acciones

### Descripción del problema<sup>15</sup>

- ▶ **Actividad crítica:** actividad por la cual nos interesa planificar una reacción.
- ▶ **Reacción:** acción que el sistema tiene que actuar cuando ocurre la actividad crítica.
- ▶ **Duración de la reacción:** duración  $t_d$  del tiempo de activación de la reacción.
- ▶ **Tiempo de actuación de la reacción:** tiempo  $t_w$  necesario al sistema para llevar a cabo la reacción desde cuando ha sido planificada.



Por ej. notificación para tomar pastillas antes de cenar:


- ▶  $t_w = 60s$
- ▶  $t_d = 120s$
- ▶ Notifica al instante  $\tilde{t}$

<sup>15</sup>Biagi, M., Carnevali, L., Paolieri, M., Patara, F. and Vicario, E., 2016, October. A Stochastic Model-Based Approach to Online Event Prediction and Response Scheduling. In European Workshop on Performance Engineering (pp. 32-47). Springer International Publishing.

## Planificación de acciones

### Política de planificación

- ▶ Se busca el **intervalo de mayor probabilidad** (de longitud  $t_d$ ) de que ocurra la actividad crítica.
- ▶ Si la **probabilidad máxima** está mas alta de un **umbral fijo**, la reacción será planificada por el sistema al instante  $\tilde{t} = x^* - t_w$ , donde  $x^*$  indica el extremo inferior del intervalo de máxima probabilidad.
- ▶ Si la probabilidad máxima está mas baja del umbral, ninguna reacción será planificada por el sistema.



*Fin.*



*Preguntas? Gracias!*