

Ambient Assisted Living y modelos estocásticos

Tommaso Papini

STLab, Departamento de la Ingeniería de la Información, Universidad de Florencia, Italia,
tommaso.papini@unifi.it

29 de Mayo 2017

Departamento de Informática, Universidad de Jaén, España

- ▶ Ambient Assisted Living
- ▶ Modelos y datasets
- ▶ Análisis de entornos inteligentes

Overview

Ambient Assisted Living

Objetivos

Modelos y datasets

Modelos estocásticos

Datasets anotados

Process mining

Análisis de entornos inteligentes

Diagnos

Predicción

Planificación de acciones

Ambient Assisted Living

Ambient Assisted Living

El **Ambient Assisted Living** es un sector de investigación que tiene como objetivo ayudar a las personas que viven en *entornos inteligentes* (es decir, dotados de sensores y actuadores) explotando a la tecnología de sensores y de procesamiento de datos.



Objetivos

Un *entorno inteligente* es un sistema **parcialmente observable**:

- ▶ el estado efectivo del sistema resulta oculto;
- ▶ solo se pueden observar eventos (*observaciones*) emitidos por el sistema (por ej. la activación de un sensor).

Principales análisis de interés:

- ▶ **Diagnosis**: estimar cual es el estado efectivo actual del sistema a partir de las observaciones registradas.
- ▶ **Predicción**: estimar cual será el estado efectivo del sistema después de una determinada cantidad de tiempo o la densidad de probabilidad de que un evento se verifique.
- ▶ **Planificación de acciones**: elegir la acción óptima y entre cuanto tiempo debe desarrollarse para evitar situaciones críticas.

Análisis en línea:


- ▶ intenta analizar un entorno inteligente *mientras* está evolucionando.

Modelos y datasets

Modelos estocásticos

Los *modelos estocásticos* representan una aproximación de sistemas donde se modelan:


- ▶ la evolución del estado del sistema;
- ▶ parámetros estocásticos que definen como el sistema pasa de un estado al otro.



Datasets anotados

Un *dataset anotado* es un dataset donde hay:


- ▶ los eventos registrados y cuando han pasado (marca temporal);
- ▶ anotaciones manuales de la evolución del estado efectivo del sistema (con intervalos temporales por cada estado).



Datasets anotados

van Kasteren

Un ejemplo clásico de dataset anotado para AAL es el dataset de *van Kasteren*¹²



¹<https://sites.google.com/site/tim0306/datasets>

²Van Kasteren, T., Noulas, A., Englebienne, G. and Kröse, B., 2008, September. Accurate activity recognition in a home setting. In Proceedings of the 10th international conference on Ubiquitous computing (pp. 1-9). ACM.

Process mining

De datasets anotados a modelos estocásticos

Con el término **process mining** se indica un conjunto de técnicas para construir un modelo estocástico de un sistema parcialmente observable a partir de un dataset anotado de este mismo sistema.


El process mining está compuesto por dos técnicas principales:

- ▶ **Process elicitation:** construye un modelo discreto (es decir, sin informaciones sobre la permanencia en los estados del sistema) a partir de los eventos y actividades anotadas en el dataset.
- ▶ **Process enhancement:** añade una visión temporal continua a un modelo discreto introduciendo parámetros estocásticos que describen como el sistema evoluciona a lo largo del tiempo utilizando medidas estadísticas obtenidas por el dataset.

Análisis de entornos inteligentes


Análisis de entornos inteligentes

Esquema general



- ▶ **Process mining:** de dataset anotado a modelo estocásticos.
- ▶ **Diagnosis:** de eventos efectivos a probabilidad del estado corriente (sobre un determinado modelo estocástico).
- ▶ **Predicción:** de probabilidad del estado corriente a probabilidad de que ocurra un evento crítico.
- ▶ **Planificación:** de probabilidad de que ocurra un evento crítico a tiempo de planificación de una reacción (con una determinada política de reacción).

Diagnósis




La **diagnósis** calcula el estado efectivo mas probable del modelo en el instante corriente a partir de los eventos observados hasta el instante corriente.

Diagnóstico

Tiempo discreto

Los **Modelos Ocultos de Márkov** (Hidden Markov Model, HMM):

- ▶ modelan a un sistema parcialmente observable sin tener en cuenta el tiempo de permanencia en cada estado;
- ▶ asocian a cada estado efectivo del sistema una distribución discreta sobre los eventos observables;
- ▶ modelan a un sistema donde los estados efectivos evolucionan como una *Cadena de Márkov Tiempo Discreto* (Discrete Time Markov Chain, DTMC).



Diagnóstico con HMM se puede lograr con algoritmos clásicos como el *algoritmo de Viterbi* o el *algoritmo de Forward-Backward*.

Diagnósis

Tiempo discreto con permanencia

▶ **HSMM³**

- ▶ Hidden Semi Markov Model;
- ▶ permanencia en los estados ocultos modelada con distribuciones de tiempo discreto;
- ▶ eventos generados en cada instante temporal.

▶ **IS-HSMM/ILP-HSMM⁴**

- ▶ Interval State-Hidden Semi Markov Model;
- ▶ Interval Length Probability-Hidden Semi Markov Model;
- ▶ extensiones de los HSMMs;
- ▶ permite modelar a intervalos de silencio (es decir, sin eventos);

³Van Kasteren, T.L.M., Englebiene, G. and Kröse, B.J., 2010. Activity recognition using semi-markov models on real world smart home datasets. Journal of ambient intelligence and smart environments, 2(3), pp.311-325.

⁴Narimatsu, H. and Kasai, H., 2016. State Duration and Interval Modeling in Hidden Semi-Markov Model for Sequential Data Analysis. arXiv preprint arXiv:1608.06954.

Diagnóstico

Tiempo continuo

- ▶ **HnMM**⁵
 - ▶ Hidden nonMarkov Model;
 - ▶ tiempos de permanencia continuos;
 - ▶ cada *transición* (es decir, el pasaje de un estado al siguiente) produce un evento.
- ▶ **GHSMM**⁶
 - ▶ Generalized Hidden Semi Markov Process;
 - ▶ tiempo de permanencia continuo;
 - ▶ solo una observación por cada estado.

⁵Buchholz, R., Krull, C., Strigl, T. and Horton, G., 2010, March. Using hidden non-markovian models to reconstruct system behavior in partially-observable systems. In Proceedings of the 3rd International ICST Conference on Simulation Tools and Techniques (p. 86). ICST (Institute for Computer Sciences, Social-Informatics and Telecommunications Engineering).

⁶Salfner, F., 2006. Modeling event-driven time series with generalized hidden semi-Markov models.

Diagnóstico

H-MRGP-M

El **Modelo Oculto de Márkov Regenerativo** (Hidden-Markov Regenerative Process-Model) ha sido desarrollado por el STLab en la Universidad de Florencia.⁷

- ▶ Modela el tiempo continuo de permanencia en los estados y del inter-tiempo entre eventos.
- ▶ El estado del modelo evoluciona como un *Proceso Regenerativo de Márkov* (Markov Regenerative Process, MRP).

⁷Carnevali, L., Nugent, C., Patara, F. and Vicario, E., 2015, September. A continuous-time model-based approach to activity recognition for ambient assisted living. In International Conference on Quantitative Evaluation of Systems (pp. 38-53). Springer International Publishing.

Diagnósis

H-MRGP-M: medidas estadísticas

- ▶ Experimentos sobre el dataset de van Kasteren:
 - ▶ 7+1 actividades.
 - ▶ {Leaving house, Preparing a beverage, Preparing breakfast, Preparing dinner, Sleeping, Taking shower, Toileting}.
- ▶ A partir de las marcas temporales en el dataset anotado, se calculan medidas estadísticas sobre los tiempos continuos
 - ▶ de permanencia en cada actividad;
 - ▶ de inter-tiempo entre eventos en cada actividad.

	Tiempo de permanencia		Inter-tiempo entre eventos	
	μ (s)	CV	μ (s)	CV
Leaving house	40 261.455	1.042	9 354.190	2.810
Preparing a beverage	35.667	1.361	7.643	2.613
Preparing breakfast	108.684	0.713	9.928	1.844
Preparing dinner	1 801.889	0.640	77.966	2.589
Sleeping	26 116.571	0.442	1 871.836	3.090
Taking shower	485.910	0.298	102.788	1.969
Toileting	88.742	1.175	14.814	2.449

Diagnósis

H-MRGP-M: modelo estocástico @runtime

- ▶ El modelo se crea con técnicas de *process mining*:
 - ▶ *process elicitation* para definir la topología del modelo;
 - ▶ *process enhancement* para añadir parámetros estocásticos a partir de las medidas estadísticas calculadas (técnica de Whitt⁸ y software PhFit⁹).
- ▶ Modelo **@runtime**: modelo actualizado cada vez que se observa un nuevo evento.¹⁰
- ▶ El formalismo utilizado para representar al modelo es el de las **Redes de Petri Temporizadas estocásticas** (stochastic Timed Petri Net, sTPN).¹¹¹²

⁸Whitt, W., 1982. Approximating a point process by a renewal process, I: Two basic methods. Operations Research, 30(1), pp.125-147.

⁹Horváth, A. and Telek, M., 2002, April. Phfit: A general phase-type fitting tool. In International Conference on Modelling Techniques and Tools for Computer Performance Evaluation (pp. 82-91). Springer Berlin Heidelberg.

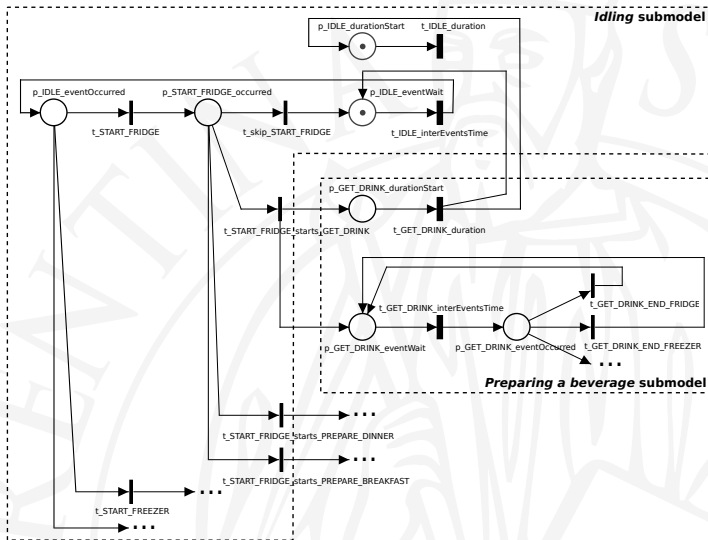
¹⁰Blair, G., Bencomo, N. and France, R.B., 2009. Models@ run. time. Computer, 42(10).

¹¹Horváth, A. and Vicario, E., 2009, September. Aggregated stochastic state classes in quantitative evaluation of non-markovian stochastic Petri nets. In Quantitative Evaluation of Systems, 2009. QEST'09. Sixth International Conference on the (pp. 155-164). IEEE.

¹²Vicario, E., 2001. Static analysis and dynamic steering of time-dependent systems. IEEE transactions on software engineering, 27(8), pp.728-748.

Diagnósis

H-MRGP-M: sTPN




Diagnosis

H-MRGP-M: análisis transitorio

Después de cada observación, se pueden calcular las probabilidades de estar en diferentes estados del sistema hasta la observación siguiente.

- Se explota a la técnica de análisis transitorio de Procesos Regenerativos de Markov basada en clases de estado estocásticas.¹³



El estado estimado por la diagnosis será el estado que lleva la probabilidad más alta.

¹³Horváth, A., Paolieri, M., Ridi, L. and Vicario, E., 2012. Transient analysis of non-Markovian models using stochastic state classes. Performance Evaluation, 69(7), pp.315-335.

Diagnóstico

H-MRGP-M: análisis transitorio




Después de haber observado el evento n , por cada actividad corriente *posible*

- ▶ se construye el árbol de las clases hasta que se encuentre la observación siguiente (evento $n + 1$);
- ▶ se seleccionan las hojas correspondientes al nuevo evento observado;
- ▶ se calcula la PDF de las hojas seleccionadas en el retraso d (inter-tiempo entre los eventos n y $n + 1$) en cada árbol, sumandolas entre sí con peso la probabilidad de la raíz;
- ▶ se restituye el máximo como actividad más probable.

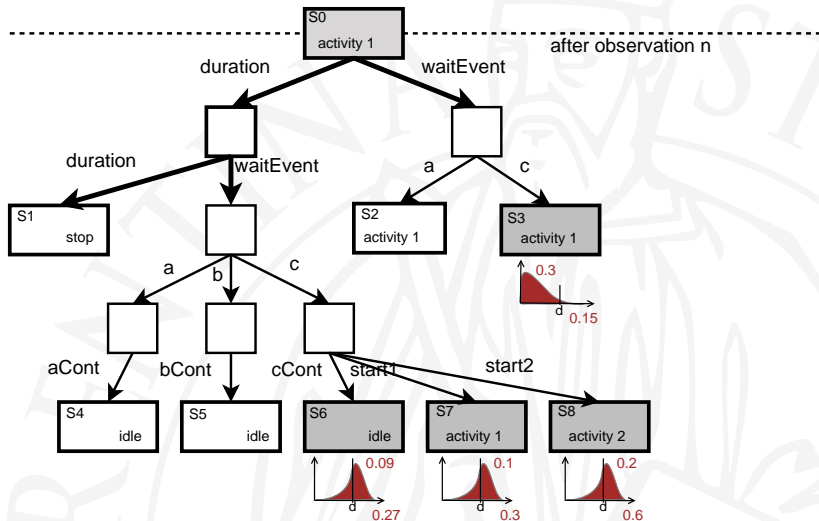
Diagnosis

H-MRGP-M: análisis transitorio




Diagnosis

H-MRGP-M: análisis transitorio



Predicción



La **predicción**¹⁴ calcula la densidad de probabilidad en el tiempo de que ocurra una determinada actividad crítica, a partir de la estimación sobre el estado corriente del modelo calculado por la diagnosis.


¹⁴Salfner, F., Lenk, M. and Malek, M., 2010. A survey of online failure prediction methods. ACM Computing Surveys (CSUR), 42(3), p.10.

Predicción

Modelo utilizado


Predicción de la densidad de probabilidad de una actividad crítica:

- ▶ Process enhancement sin elicitation:
 - ▶ probabilidades de transición calculadas por las medidas estadísticas sobre las marcas temporales.
- ▶ Estados *idle* especializados:
 - ▶ permite tener en cuenta la última actividad.
- ▶ Las actividades evolucionan como un *Proceso Semi Márkov* (Semi Markov Process, SMP).




Predicción

Calculo de la PDF




- ▶ Para cada estado posible, se calcula la densidad de probabilidad de alcanzar al estado crítico (análisis transitorio).
- ▶ Se suman entre sí las densidades de probabilidad a partir de cada estado posible, comparándolas con la probabilidad de estar en cada estado.


$PDF(t)_{A_to_F} * \pi_A$




$PDF(t)_{B_to_F} * \pi_B$



$PDF(t)_{to_F}$



Planificación de acciones




La **planificación de acciones** calcula el instante temporal óptimo para planificar una reacción oportuna a una determinada actividad crítica, a partir de la probabilidad de que dicha actividad ocurra (calculada por la predicción) y de una política de reacción (decidida por el usuario).

Planificación de acciones

Descripción del problema¹⁵

- ▶ **Actividad crítica:** actividad por la cual nos interesa planificar una reacción.
- ▶ **Reacción:** acción que el sistema tiene que actuar cuando ocurre la actividad crítica.
- ▶ **Duración de la reacción:** duración t_d del tiempo de activación de la reacción.
- ▶ **Tiempo de actuación de la reacción:** tiempo t_w necesario al sistema para llevar a cabo la reacción desde cuando ha sido planificada.



Por ej. notificación para tomar pastillas antes de cenar:


- ▶ $t_w = 60s$
- ▶ $t_d = 120s$
- ▶ Notifica al instante \tilde{t}

¹⁵Biagi, M., Carnevali, L., Paolieri, M., Patara, F. and Vicario, E., 2016, October. A Stochastic Model-Based Approach to Online Event Prediction and Response Scheduling. In European Workshop on Performance Engineering (pp. 32-47). Springer International Publishing.

Planificación de acciones

Política de planificación

- ▶ Se busca el **intervalo de mayor probabilidad** (de longitud t_d) de que ocurra la actividad crítica.
- ▶ Si la **probabilidad máxima** está mas alta de un **umbral fijo**, la reacción será planificada por el sistema al instante $\tilde{t} = x^* - t_w$, donde x^* indica el extremo inferior del intervalo de máxima probabilidad.
- ▶ Si la probabilidad máxima está mas baja del umbral, ninguna reacción será planificada por el sistema.



Fin.



Preguntas? Gracias!