

Ambient Assisted Living y modelos estocásticos

Tommaso Papini

STLab, Departamento de la Ingeniería de la Información, Universidad de Florencia, Italia,
tommaso.papini@unifi.it

29 de Mayo 2017

Departamento de Informática, Universidad de Jaén, España

- ▶ Ambient Assisted Living
- ▶ Modelos y datasets
- ▶ Análisis de entornos inteligentes

Overview

Ambient Assisted Living

Objetivos

Modelos y datasets

Modelos estocásticos

Datasets anotados

Process mining

Análisis de entornos inteligentes

Diagnosis

Predicción

Planificación de acciones

Ambient Assisted Living

El **Ambient Assisted Living** es un sector de investigación que tiene como objetivo lo de ayudar a las personas que viven en *entornos inteligentes* (es decir, dotados de sensores y actuadores) explotando a la tecnología de sensores y de procesamiento de datos.



Objetivos

Un *entorno inteligente* es un sistema **parcialmente observable**:

- ▶ el estado efectivo del sistema resulta oculto;
- ▶ solo se pueden observar eventos (*observaciones*) emitidos por el sistema (por ej. la activación de un sensor).

Principales análisis de interese:

- ▶ **Diagnosis**: estimar cual es el estado efectivo actual del sistema a partir de las observaciones registradas.
- ▶ **Predicción**: estimar cual será el estado efectivo del sistema después de una determinada cantidad de tiempo o la densidad de probabilidad de que un evento se verifique.
- ▶ **Planificación de acciones**: elegir la acción optima y entre cuanto tiempo ir actuarla para evitar situaciones críticas.

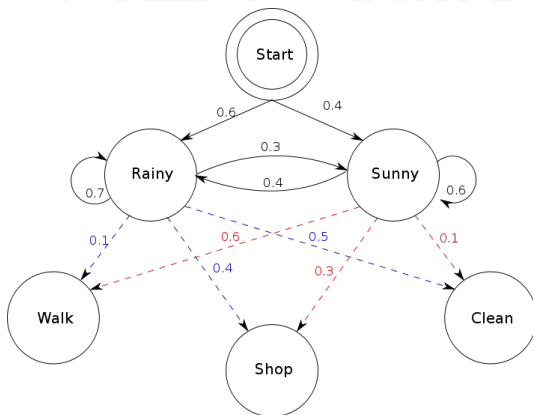
Análisis en linea:

- ▶ intenta analizar a un entorno inteligente *mientras* está evolucionando.

Modelos estocásticos

Los *modelos estocásticos* representan una aproximación de sistemas donde se modelan:

- ▶ la evolución del estado del sistema;
- ▶ parámetros estocásticos que definen como el sistema pasa de un estado al otro.




Datasets anotados

Un *dataset anotado* es un dataset donde hay:

- ▶ los eventos registrados y cuando han pasado (marca temporal);
- ▶ anotaciones manuales de la evolución del estado efectivo del sistema (con intervalos temporales por cada estado).

Un ejemplo clásico de dataset anotado para AAL es el dataset de *van Kasteren*¹²



¹<https://sites.google.com/site/tim0306/datasets>

²Van Kasteren, T., Noulas, A., Englebienne, G. and Kröse, B., 2008, September. Accurate activity recognition in a home setting. In Proceedings of the 10th international conference on Ubiquitous computing (pp. 1-9). ACM.

Process mining

De datasets anotados a modelos estocásticos


Con el término **process mining** se indica un conjunto de técnicas para construir a un modelo estocástico de un sistema parcialmente observable a partir de un dataset anotado de este mismo sistema.

El process mining está compuesto por dos técnicas principales:

- ▶ **Process elicitation:** construye un modelo discreto (es decir, sin informaciones sobre la permanencia en los estados del sistema) a partir de los eventos y actividades anotados en el dataset.
- ▶ **Process enhancement:** añade una visión temporal continua a un modelo discreto introduciendo parámetros estocásticos que describen como el sistema evoluciona a lo largo del tiempo utilizando medidas estadísticas sacadas por el dataset.

Análisis de entornos inteligentes

Esquema general




- ▶ **Process mining:** de dataset anotado a modelo estocásticos.
- ▶ **Diagnosis:** de eventos efectivos a probabilidad del estado corriente (sobre un determinado modelo estocástico).
- ▶ **Predicción:** de probabilidad del estado corriente a probabilidad de que ocurra un evento crítico.
- ▶ **Planificación:** de probabilidad de que ocurra un evento crítico a tiempo de planificación de una reacción (con una determinada política de reacción).

Diagnóstico

Tiempo discreto

Los **Modelos Ocultos de Márkov** (Hidden Markov Model, HMM):

- ▶ modelan a un sistema parcialmente observable sin tener en cuenta del tiempo de permanencia en cada estado;
- ▶ asocian a cada estado efectivo del sistema una distribución discreta sobre los eventos observables;
- ▶ modelan a un sistema donde los estados efectivos evolucionan como una *Cadena de Márkov Tiempo Discreto* (Discrete Time Markov Chain, DTMC).



Diagnóstico con HMM se puede lograr con algoritmos clásicos como el *algoritmo de Viterbi* o el *algoritmo de Forward-Backward*.

Diagnósis

Tiempo discreto con permanencia

▶ **HSMM³**

- ▶ Hidden Semi Markov Model;
- ▶ permanencia en los estados ocultos modelada con distribuciones de tiempo discreto;
- ▶ eventos generados en cada instante temporal.

▶ **IS-HSMM/ILP-HSMM⁴**

- ▶ Interval State-Hidden Semi Markov Model;
- ▶ Interval Length Probability-Hidden Semi Markov Model;
- ▶ extensiones de los HSMMs;
- ▶ permite modelar a intervalos de silencio (es decir, sin eventos);

³Van Kasteren, T.L.M., Englebienne, G. and Kröse, B.J., 2010. Activity recognition using semi-markov models on real world smart home datasets. Journal of ambient intelligence and smart environments, 2(3), pp.311-325.

⁴Narimatsu, H. and Kasai, H., 2016. State Duration and Interval Modeling in Hidden Semi-Markov Model for Sequential Data Analysis. arXiv preprint arXiv:1608.06954.

Diagnóstico

Tiempo continuo

- ▶ **HnMM**⁵
 - ▶ Hidden nonMarkov Model;
 - ▶ tiempos de permanencia continuos;
 - ▶ cada *transición* (es decir, el pasaje de un estado al siguiente) produce un evento.
- ▶ **GHSMM**⁶
 - ▶ Generalized Hidden Semi Markov Process;
 - ▶ tiempo de permanencia continuo;
 - ▶ solo una observación por cada estado.

⁵Buchholz, R., Krull, C., Strigl, T. and Horton, G., 2010, March. Using hidden non-markovian models to reconstruct system behavior in partially-observable systems. In Proceedings of the 3rd International ICST Conference on Simulation Tools and Techniques (p. 86). ICST (Institute for Computer Sciences, Social-Informatics and Telecommunications Engineering).

⁶Salfner, F., 2006. Modeling event-driven time series with generalized hidden semi-Markov models.

Diagnóstico

H-MRGP-M

El **Modelo Oculto de Márkov Regenerativo** (Hidden-Markov Regenerative Process-Model) ha sido desarrollado por el STLab en la Universidad de Florencia.⁷

- ▶ Modela el tiempo continuo de permanencia en los estados y del inter-tiempo entre eventos.
- ▶ El estado del modelo evoluciona como un *Proceso Regenerativo de Márkov* (Markov Regenerative Process, MRP).

⁷Carnevali, L., Nugent, C., Patara, F. and Vicario, E., 2015, September. A continuous-time model-based approach to activity recognition for ambient assisted living. In International Conference on Quantitative Evaluation of Systems (pp. 38-53). Springer International Publishing.

Diagnosis

H-MRGP-M: tiempos continuos

- ▶ Experimentado sobre el dataset de van Kasteren:
 - ▶ 7+1 actividades.
 - ▶ {Leaving house, Preparing a beverage, Preparing breakfast, Preparing dinner, Sleeping, Taking shower, Toileting}.
- ▶ A partir de las marcas temporales en el dataset anotado, se calculan medidas estadísticas sobre los tiempos continuos
 - ▶ de permanencia en cada actividad;
 - ▶ de inter-tiempo entre eventos en cada actividad.

	Tiempo de permanencia		Inter-tiempo entre eventos	
	μ (s)	CV	μ (s)	CV
Leaving house	40 261.455	1.042	9 354.190	2.810
Preparing a beverage	35.667	1.361	7.643	2.613
Preparing breakfast	108.684	0.713	9.928	1.844
Preparing dinner	1 801.889	0.640	77.966	2.589
Sleeping	26 116.571	0.442	1 871.836	3.090
Taking shower	485.910	0.298	102.788	1.969
Toileting	88.742	1.175	14.814	2.449

Diagnósis

H-MRGP-M: modelo estocástico @runtime

- ▶ El modelo se crea con técnicas de *process mining*:
 - ▶ *process elicitation* para definir la topología del modelo;
 - ▶ *process enhancement* para añadir parámetros estocásticos a partir de las medidas estadísticas calculadas (estrategia de Whitt⁸ y software PhFit⁹).
- ▶ Modelo **@runtime**: modelo actualizado cada vez que se observa un nuevo evento.¹⁰
- ▶ El formalismo utilizado para representar al modelo es el de las **Redes de Petri Temporizadas estocásticas** (stochastic Timed Petri Net, sTPN).¹¹¹²

⁸Whitt, W., 1982. Approximating a point process by a renewal process, I: Two basic methods. Operations Research, 30(1), pp.125-147.

⁹Horváth, A. and Telek, M., 2002, April. Phfit: A general phase-type fitting tool. In International Conference on Modelling Techniques and Tools for Computer Performance Evaluation (pp. 82-91). Springer Berlin Heidelberg.


¹⁰Blair, G., Bencomo, N. and France, R.B., 2009. Models@ run. time. Computer, 42(10).

¹¹Horváth, A. and Vicario, E., 2009, September. Aggregated stochastic state classes in quantitative evaluation of non-markovian stochastic Petri nets. In Quantitative Evaluation of Systems, 2009. QEST'09. Sixth International Conference on the (pp. 155-164). IEEE.

¹²Vicario, E., 2001. Static analysis and dynamic steering of time-dependent systems. IEEE transactions on software engineering, 27(8), pp.728-748.

Diagnósis

H-MRGP-M: sTPN




Diagnósis

H-MRGP-M: probabilidades

Después de cada observación, se pueden calcular las probabilidades de ser en diferentes estados del sistema hasta la observación siguiente.

- Se explota a la técnica de análisis transitorio de Procesos Regenerativos de Markov basada en clases de estado estocásticas.¹³

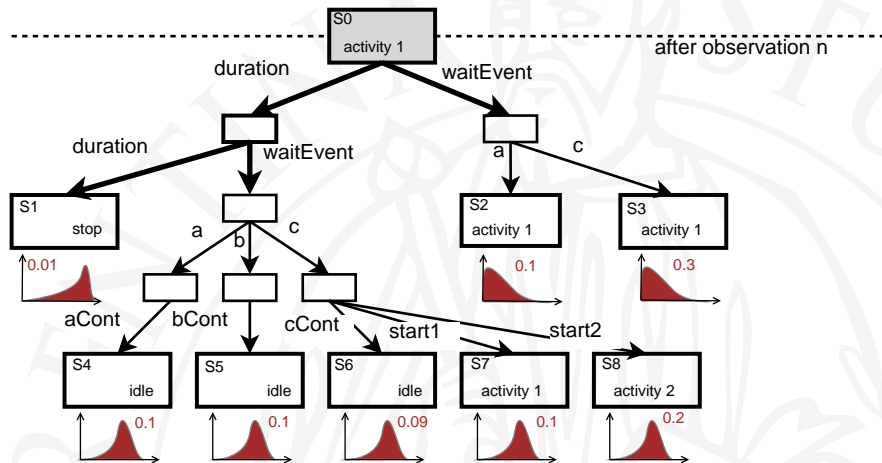


El estado estimado por la diagnóstico será el estado que lleva la probabilidad más alta.

¹³Horváth, A., Paolieri, M., Ridi, L. and Vicario, E., 2012. Transient analysis of non-Markovian models using stochastic state classes. Performance Evaluation, 69(7), pp.315-335.

Diagnosis


H-MRGP-M: probabilidades



Predicción¹⁴


Predicción de la densidad de probabilidad de una actividad crítico:

- ▶ Process enhancement sin elicitation:
 - ▶ probabilidades de transición calculadas por las medidas estadísticas sobre las marcas temporales.
- ▶ Estados *idle* especializados:
 - ▶ permite tener en cuenta la última actividad.
- ▶ Las actividades evolucionan como un *Proceso Semi Márkov* (Semi Markov Process, SMP).






¹⁴Salfner, F., Lenk, M. and Malek, M., 2010. A survey of online failure prediction methods. ACM Computing Surveys (CSUR), 42(3), p.10.

Predicción



- ▶ Para cada estado posible, se calcula la densidad de probabilidad de alcanzar al estado crítico (análisis transitorio).
- ▶ Se suman entre sí las densidades de probabilidad a partir de cada estado posible, pesadas por la probabilidad de ser en cada estado.

 $PDF(t)_{A_to_F} * \pi_A$

 $PDF(t)_{B_to_F} * \pi_B$

 $PDF(t)_{to_F}$



+

=

Planificación de acciones

Descripción del problema

- ▶ **Actividad crítica:** actividad por la cual nos interesa planificar una reacción.
- ▶ **Reacción:** acción que el sistema tiene que actuar cuando ocurre la actividad crítica.
- ▶ **Duración de la reacción:** duración t_d del tiempo de activación de la reacción.
- ▶ **Tiempo de actuación de la reacción:** tiempo t_w necesario al sistema para actuar a la reacción desde cuando ha sido planificada.




Por ej. notificación para tomar píldoras antes de cenar:

- ▶ $t_w = 60s$
- ▶ $t_d = 120s$
- ▶ Notifica al instante \tilde{t}

Planificación de acciones

Política de planificación¹⁵

- ▶ Se busca al **intervalo de mayor probabilidad** (de longitud t_d) de que ocurra la actividad crítica.
- ▶ Si la **probabilidad máxima** está mas alta de un **umbral fijo**, la reacción será planificada por el sistema al instante $\tilde{t} = x^* - t_w$, donde x^* indica el extremo inferior del intervalo de máxima probabilidad.
- ▶ Si la probabilidad máxima está mas baja del umbral, ninguna reacción será planificada por el sistema.



¹⁵Biagi, M., Carnevali, L., Paolieri, M., Patara, F. and Vicario, E., 2016, October. A Stochastic Model-Based Approach to Online Event Prediction and Response Scheduling. In European Workshop on Performance Engineering (pp. 32-47). Springer International Publishing.

Fin.



Preguntas? Gracias!